



图像分割的变分水平集方法

—以local binary fitting为例

李佳翔

November 27, 2017



Outline

图像分割中的变分水平集方法

- 图像处理

- 图像处理中的变分方法

- 变分方法与图像分割：几个模型概述

Local Binary Fitting

- Methods

- Implementation and Results



图像处理

任意一个图像处理器 T ，对输入图像 u_0 进行处理

$$u_0 \xrightarrow{T} F = T[u_0]$$

针对不同的 T 得到的是不同的问题，一般地 u_0 是低质量的图像，而 F 是我们预期通过处理得到的高质量图像。图像处理的难度也就在这里：往往处理问题为反问题。



图像处理

任意一个图像处理器 T ，对输入图像 u_0 进行处理

$$u_0 \xrightarrow{T} F = T[u_0]$$

针对不同的 T 得到的是不同的问题，一般地 u_0 是低质量的图像，而 F 是我们预期通过处理得到的高质量图像。图像处理的难度也就在这里：往往处理问题为反问题。
通常关注的图像处理问题有降噪、去模糊、修补或图像插值以及分割。

●●○○○
○○○○○
○○○○○○○○○

○○○○○
○○○

图像处理

以对比度问题为例。如果是 u_0 是原始图像简单的线性变换，那么问题就好解决。如果变换依旧是逐元素进行的，但是不再是线性的，那么问题就会棘手一些。





图: Einstein in contrast variations: left: original figure; center: element-wise linear transform; right: element-wise non-linear transform



图像处理

图像处理的诸多操作，包括阈值法(thresholding)、滤波器(filter)等，如下图所示为移动平均阈值：

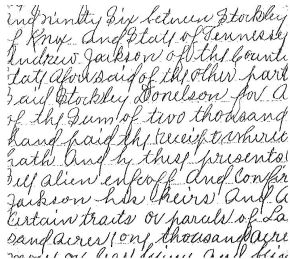
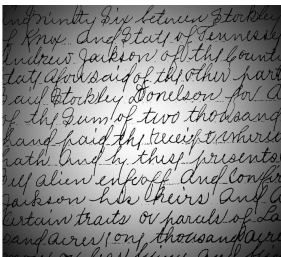


图: Moving average thresholding



图像处理

下图为梯度算子:




图: Nabl with Lena



图像分割

图像分割在联系底层和高层计算机视觉上至关重要，分割对人类来说很简单，但是对机器而言难度很大。



图像分割

图像分割在联系底层和高层计算机视觉上至关重要，分割对人类来说很简单，但是对机器而言难度很大。

数学定义：在给定二维区域 Ω 上有观察图像 u_0 ，求 Ω 分划 $\Omega_0, \dots, \Omega_N$ ，使得 Ω_i 在“视觉上有意义”。进一步的问题有：确定 N ，甚至真正确定“物体”。



图像分割

图像分割在联系底层和高层计算机视觉上至关重要，分割对人类来说很简单，但是对机器而言难度很大。

数学定义：在给定二维区域 Ω 上有观察图像 u_0 ，求 Ω 分划 $\Omega_0, \dots, \Omega_N$ ，使得 Ω_i 在“视觉上有意义”。进一步的问题有：确定 N ，甚至真正确定“物体”。




图: Image segmentation instance



图像处理的变分方法

一个图像复原的例子

考虑下面的加性噪声模型：

$$u_0(x) = u(x) + n(x)$$

其中 n 是期望为0的Gauss白噪声场。如果已知 u_0 ，那么求解 u 的过程可以通过极小化以下能量泛函得到：



图像处理的变分方法

一个图像复原的例子

考虑下面的加性噪声模型：

$$u_0(x) = u(x) + n(x)$$

其中 n 是期望为0的Gauss白噪声场。如果已知 u_0 ，那么求解 u 的过程可以通过极小化以下能量泛函得到：

$$\hat{u} = \operatorname{argmin}_u E(u) = \operatorname{argmin}_u \frac{\alpha}{2} \int_{\Omega} (u - u_0)^2 dx + \frac{\lambda}{2} \int_{\Omega} |\nabla u|^2 dx$$

其中第一项是保真项(fidelity)，第二项是光滑项，它保证了还原出来的图像梯度比较小(从而减小噪声)。



一个图像复原的例子

这个例子同时还帮助我们引入了PDE的方法。回忆Poisson方程求解的弱形式：



一个图像复原的例子

这个例子同时还帮助我们引入了PDE的方法。回忆Poisson方程求解的弱形式：

$E(u) = \int_{\Omega} \frac{1}{2} [|\nabla u|^2 - uf] dx$ 在Sobolev空间 $W^{1,2}(\Omega)$ 中的临界点在弱导数意义下合于以下Neumann问题：

$$\begin{cases} -\Delta u = f, & x \in \Omega \\ \frac{\partial u}{\partial \nu} = 0, & x \in \partial\Omega \end{cases}$$



一个图像复原的例子

这个例子同时还帮助我们引入了PDE的方法。回忆Poisson方程求解的弱形式：

$E(u) = \int_{\Omega} \frac{1}{2} [|\nabla u|^2 - uf] dx$ 在Sobolev空间 $W^{1,2}(\Omega)$ 中的临界点在弱导数意义下合于以下Neumann问题：

$$\begin{cases} -\Delta u = f, & x \in \Omega \\ \frac{\partial u}{\partial \nu} = 0, & x \in \partial\Omega \end{cases}$$

从而优化 $E(u) = \frac{\alpha}{2} \int_{\Omega} (u - u_0)^2 dx + \frac{\lambda}{2} \int_{\Omega} |\nabla u|^2 dx$ 等价于以下PDE：

$$\begin{cases} -\lambda \Delta u + \alpha u = \lambda u_0, & x \in \Omega \\ \frac{\partial u}{\partial \nu} = 0, & x \in \partial\Omega \end{cases}$$



一个图像复原的例子

下面我们对于这个问题介绍优化算法：梯度流方法。



一个图像复原的例子

下面我们对于这个问题介绍优化算法：梯度流方法。

引入时间参数 t ，我们认为 $\frac{\partial u}{\partial t}$ 是朝着使 $E(u)$ 下降的方向前进的。即

$$\frac{\partial u}{\partial t} = -\frac{\delta E(u)}{\delta u}$$

其中 $\frac{\delta E(u)}{\delta u}$ 是 $E(u)$ 关于 u 的一阶变分，它反应了 $E(u)$ 在 u 变化下的变化率。



一个图像复原的例子

由一阶变分的公式：若 $E(u) = \int_{\Omega} F(x, u, \nabla u) dx$ ，且 u 在 Ω 中紧支，那么

$$\frac{\delta E(u)}{\delta u} = \frac{\partial F}{\partial u} - \frac{d}{dx} \frac{\partial F}{\partial u_x} - \frac{d}{dy} \frac{\partial F}{\partial u_y}$$



一个图像复原的例子

由一阶变分的公式：若 $E(u) = \int_{\Omega} F(x, u, \nabla u) dx$ ，且 u 在 Ω 中紧支，那么

$$\frac{\delta E(u)}{\delta u} = \frac{\partial F}{\partial u} - \frac{d}{dx} \frac{\partial F}{\partial u_x} - \frac{d}{dy} \frac{\partial F}{\partial u_y}$$

直接带入 $F(u) = \frac{\alpha}{2}(u - u_0)^2 + \frac{\lambda}{2}|\nabla u|^2$ 中得到

$$\frac{\partial u}{\partial t} = \alpha(u_0 - u) + \lambda \Delta u$$



一个图像复原的例子

由一阶变分的公式：若 $E(u) = \int_{\Omega} F(x, u, \nabla u) dx$ ，且 u 在 Ω 中紧支，那么

$$\frac{\delta E(u)}{\delta u} = \frac{\partial F}{\partial u} - \frac{d}{dx} \frac{\partial F}{\partial u_x} - \frac{d}{dy} \frac{\partial F}{\partial u_y}$$

直接带入 $F(u) = \frac{\alpha}{2}(u - u_0)^2 + \frac{\lambda}{2}|\nabla u|^2$ 中得到

$$\frac{\partial u}{\partial t} = \alpha(u_0 - u) + \lambda \Delta u$$

不要忘了Neumann边界条件： $\frac{\partial u}{\partial \nu} = 0$, $x \in \partial\Omega$ 。

这样，通过 $u(t+1) = u(t) + \delta \frac{\partial u}{\partial t}$ 就可以离散化迭代求解 u



图像的水平集表示

图像作为函数，可以被理解为等高线的集合(如灰度图，那么同灰度的点构成等高线)，这样自然地我们就把水平集(level set)引入图像处理之中。



图像的水平集表示

图像作为函数，可以被理解为等高线的集合(如灰度图，那么同灰度的点构成等高线)，这样自然地我们就把水平集(level set)引入图像处理之中。

考虑定义在二维有界区域 Ω 上的灰度图 $u = u(x)$. $x \in \Omega$ ，对 $\forall \lambda \in \mathbb{R}$ ，定义水平集

$$\gamma_\lambda = \{x \in \Omega | u(x) = \lambda\}$$

则 $\Gamma_u = \{\gamma_\lambda | \lambda \in \mathbb{R}\}$ 是 u 的水平集表示。 Γ_u 是 Ω 的一个分划。



图像的水平集表示

如果 u 是光滑正则的(即 $\nabla u \neq 0$)。根据正则函数的co-area公式, 我们有

$$\int_{\Omega} |\nabla u| dx = \int_{-\infty}^{\infty} \text{length}(\gamma_{\lambda}) d\lambda$$

更一般地说, 对任何函数 $\phi = \phi(u)$, 都有

$$\int_{\Omega} \phi(u) |\nabla u| dx = \int_{-\infty}^{\infty} \phi(\lambda) \text{length}(\gamma_{\lambda}) d\lambda$$

这个公式在诸多模型中都有重要作用。



Mumford-Shah模型

Mumford和Shah在1989年提出了一种对于图像处理极有启发性的理解：在大多数情况下，一个物体表面具有一致的特征，那么排除光学和表面纹理的影响，任何图像应该都可以由分片常值和分片光滑函数来近似。



Mumford-Shah模型

Mumford和Shah在1989年提出了一种对于图像处理极有启发性的理解：在大多数情况下，一个物体表面具有一致的特征，那么排除光学和表面纹理的影响，任何图像应该都可以由分片常值和分片光滑函数来近似。

分片常值函数可以表示为 $u(x) = \sum_{i=1}^N U_i \chi_i(x)$ ，其中 $\chi_i(x) = \chi_{\Omega_i}(x)$ 是集合 Ω_i 的示性函数。显然分片光滑函数类似为 $u(x) = \sum_{i=1}^N U_i(x) \chi_i(x)$ 。



Mumford-Shah模型

Mumford和Shah在1989年提出了一种对于图像处理极有启发性的理解：在大多数情况下，一个物体表面具有一致的特征，那么排除光学和表面纹理的影响，任何图像应该都可以由分片常值和分片光滑函数来近似。

分片常值函数可以表示为 $u(x) = \sum_{i=1}^N U_i \chi_i(x)$ ，其中 $\chi_i(x) = \chi_{\Omega_i}(x)$ 是集合 Ω_i 的示性函数。显然分片光滑函数类似

为 $u(x) = \sum_{i=1}^N U_i(x) \chi_i(x)$ 。

Mumford和Shah认为这一模型尤其适合做图像分割，因为图像内部的一致性直接保证了分割的合理性。如果我们假设区域“理想化”地可以被分为(称为Lipschitz分解)

$$\Omega = \cup_{m=1}^M \Omega_m \cup \Gamma$$

其中 Γ 是边界，并且有光滑假设： $u_m = u|_{\Omega_m}$, $m = 1, \dots, M$ 是光滑函数



Mumford-Shah模型

Mumford和Shah同时对图像的复杂情况作出如下的简单假设：

三维场景 \rightarrow 理想图像 $u \rightarrow$ 模糊 $K \rightarrow$ 噪声 $n \rightarrow$ 观察图像 u_0

即 $u_0 = n + Ku$, 模糊算子 K 可以是非线性的。



Mumford-Shah模型

Mumford和Shah同时对图像的复杂情况作出如下的简单假设：

三维场景 \rightarrow 理想图像 $u \rightarrow$ 模糊 $K \rightarrow$ 噪声 $n \rightarrow$ 观察图像 u_0

即 $u_0 = n + Ku$, 模糊算子 K 可以是非线性的。

有了以上假设，我们可以构造对应的能量泛函形式。根据我们的假设， Ω_m 内部应当是光滑甚至是常数，那么光滑项

$$\sum_{m=1}^M \int_{\Omega_m} |\nabla u_m|^2 dx = \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx$$

应当足够小。



Mumford-Shah模型

Mumford和Shah同时对图像的复杂情况作出如下的简单假设：

三维场景 \rightarrow 理想图像 $u \rightarrow$ 模糊 $K \rightarrow$ 噪声 $n \rightarrow$ 观察图像 u_0

即 $u_0 = n + Ku$, 模糊算子 K 可以是非线性的。

有了以上假设，我们可以构造对应的能量泛函形式。根据我们的假设， Ω_m 内部应当是光滑甚至是常数，那么光滑项

$$\sum_{m=1}^M \int_{\Omega_m} |\nabla u_m|^2 dx = \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx$$

应当足够小。

我们希望分划曲线 Γ 长度不要太大，这也保证了分划曲线的光滑性，所以第二项约束是：

$$\mathcal{H}^1(\Gamma) = \text{length}(\Gamma)$$

尽可能的小。



Mumford-Shah模型

Mumford和Shah同时对图像的复杂情况作出如下的简单假设：

三维场景 \rightarrow 理想图像 $u \rightarrow$ 模糊 $K \rightarrow$ 噪声 $n \rightarrow$ 观察图像 u_0

即 $u_0 = n + Ku$, 模糊算子 K 可以是非线性的。

有了以上假设，我们可以构造对应的能量泛函形式。根据我们的假设， Ω_m 内部应当是光滑甚至是常数，那么光滑项

$$\sum_{m=1}^M \int_{\Omega_m} |\nabla u_m|^2 dx = \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx$$

应当足够小。

我们希望分划曲线 Γ 长度不要太大，这也保证了分划曲线的光滑性，所以第二项约束是：

$$\mathcal{H}^1(\Gamma) = \text{length}(\Gamma)$$

尽可能的小。

最终能量函数的形式为 $E(u) = \alpha \mathcal{H}^1(\Gamma) + \beta \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx$



Mumford-Shah模型

第三项约束，目的是降低噪声。假设图像中的加性噪声 n 为方差为 σ^2 的均质Gauss白噪声，那么方差可以被近似估计算子所近似：

$$\sigma^2 \cong \frac{1}{|\Omega|} \int_{\Omega} (u_0 - Ku)^2 dx$$

其中 $|\Omega|$ 为Lebesgue测度，并假设 u 是已知的。



Mumford-Shah模型

第三项约束，目的是降低噪声。假设图像中的加性噪声 n 为方差为 σ^2 的均质Gauss白噪声，那么方差可以被近似估计算子所近似：

$$\sigma^2 \cong \frac{1}{|\Omega|} \int_{\Omega} (u_0 - Ku)^2 dx$$

其中 $|\Omega|$ 为Lebesgue测度，并假设 u 是已知的。
通过引入Lagrange乘子 λ ，最终的模型是

$$\min \alpha \mathcal{H}^1(\Gamma) + \beta \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx + \lambda \int_{\Omega} (u_0 - Ku)^2 dx$$



Mumford-Shah模型

第三项约束，目的是降低噪声。假设图像中的加性噪声 n 为方差为 σ^2 的均质Gauss白噪声，那么方差可以被近似估计算子所近似：

$$\sigma^2 \cong \frac{1}{|\Omega|} \int_{\Omega} (u_0 - Ku)^2 dx$$

其中 $|\Omega|$ 为Lebesgue测度，并假设 u 是已知的。
通过引入Lagrange乘子 λ ，最终的模型是

$$\min \alpha \mathcal{H}^1(\Gamma) + \beta \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx + \lambda \int_{\Omega} (u_0 - Ku)^2 dx$$

显然 Ku 未知，我们不能按照这一模型求解。这一模型有着非常好的理论性质，作为一个模板，为之后人们的改进工作提供了基础。



变分方法与图像分割：几个模型概述

活动轮廓模型

活动轮廓模型专注于分割边界 Γ 的优化。除了我们之前提到的 $\mathcal{H}^1(\Gamma)$ ，也就是长度，我们期望一个关于边像素的能量函数 $g = g(u, \nabla u, \Delta u, \dots)$ ，使得它满足以下的性质：



变分方法与图像分割：几个模型概述

活动轮廓模型

活动轮廓模型专注于分割边界 Γ 的优化。除了我们之前提到的 $\mathcal{H}^1(\Gamma)$ ，也就是长度，我们期望一个关于边像素的能量函数 $g = g(u, \nabla u, \Delta u, \dots)$ ，使得它满足以下的性质：

- 空间平移不变性： $g(x + a, u(x + a), \dots) = g(x, u(x), \dots)$ 对 $\forall u$ 成立，
- 灰度水平平移不变性： $g(x, \lambda + u, \dots) = g(x, u, \dots)$ 对 $\forall \lambda$ 成立，
- 旋转不变性： 对 $\forall Q \in O(2)$ 即任意平面旋转，
 $g(Qx, u(Qx), \dots) = g(x, u(x), \dots)$ 成立。



变分方法与图像分割：几个模型概述

活动轮廓模型

活动轮廓模型专注于分割边界 Γ 的优化。除了我们之前提到的 $\mathcal{H}^1(\Gamma)$ ，也就是长度，我们期望一个关于边像素的能量函数 $g = g(u, \nabla u, \Delta u, \dots)$ ，使得它满足以下的性质：

- 空间平移不变性： $g(x + a, u(x + a), \dots) = g(x, u(x), \dots)$ 对 $\forall u$ 成立，
- 灰度水平平移不变性： $g(x, \lambda + u, \dots) = g(x, u, \dots)$ 对 $\forall \lambda$ 成立，
- 旋转不变性：对 $\forall Q \in O(2)$ 即任意平面旋转， $g(Qx, u(Qx), \dots) = g(x, u(x), \dots)$ 成立。

空间平移不变性说明 g 不可能显式地依赖于 x ，故 $g = g(u, \nabla u, \dots)$ ；灰度水平平移不变性说明 g 与 u 无关；最后旋转不变性说明：

$$g(Q^T \nabla u, \dots) = g(\nabla u)$$

说明 $g = g(|\nabla u|, \kappa_1, \kappa_2)$ ，其中 κ_1, κ_2 为Hessian阵的两个特征值，且 $\kappa_1 + \kappa_2 = \Delta u$ ，所以为方便我们经常令

$$g = g(|\nabla u|, \Delta u)$$

这就是满足假设的常用的能量函数形式。



活动轮廓模型

一般地，出于减少计算量等原因，我们设 g 是一阶的： $g = g(|\nabla u|)$ 。我们期望在边像素的梯度应当尽可能的大，这样能够达到最好的区分(不同的物体交界处一般是有剧烈变化的)，所以要求：

$$\frac{\partial g(|\nabla u|)}{\partial |\nabla u|} < 0$$



活动轮廓模型

一般地, 出于减少计算量等原因, 我们设 g 是一阶的: $g = g(|\nabla u|)$ 。我们期望在边像素的梯度应当尽可能的大, 这样能够达到最好的区分(不同的物体交界处一般是有剧烈变化的), 所以要求:

$$\frac{\partial g(|\nabla u|)}{\partial |\nabla u|} < 0$$

文献中经常取 g 为Cauchy衰减函数:

$$g(p) = \frac{1}{1 + ap^2}, \quad p = |\nabla u|, \quad a > 0$$

或Gauss衰减函数:

$$g(p) = e^{-bp^2}, \quad p = |\nabla u|, \quad b > 0$$



活动轮廓模型

一般地，出于减少计算量等原因，我们设 g 是一阶的： $g = g(|\nabla u|)$ 。我们期望在边像素的梯度应当尽可能的大，这样能够达到最好的区分(不同的物体交界处一般是有剧烈变化的)，所以要求：

$$\frac{\partial g(|\nabla u|)}{\partial |\nabla u|} < 0$$

文献中经常取 g 为Cauchy衰减函数：

$$g(p) = \frac{1}{1 + ap^2}, \quad p = |\nabla u|, \quad a > 0$$

或Gauss衰减函数：

$$g(p) = e^{-bp^2}, \quad p = |\nabla u|, \quad b > 0$$

这样我们能够推出一个原始的活动边界模型：

$$E(u) = \alpha \int_{\Gamma} ds + \mu \int_{\Gamma} g(|\nabla u|) ds$$

比较有名的活动轮廓模型，有Snake模型。



Chan-Vese模型

活动轮廓模型有许多发展，其中有名的是Chan和Vese提出的模型，他们的模型和Mumford-Shah模型十分相似。我们以分割内外区域(即将图像分割成两部分)的问题介绍这一模型。如果我们已知分割区域内外的平均值 c_1, c_2 ，即函数 $c(x) = c_1, x$ 在区域内,且 $c(x) = c_2, x$ 在区域外。通过优化

$$E(\Gamma) = \alpha \int_{\Gamma} ds + \frac{\lambda}{2} \int_{\Omega \setminus \Gamma} (u - c)^2 dx$$

应当也可以得到比较精确的分割。



Chan-Vese模型

活动轮廓模型有许多发展，其中有名的是Chan和Vese提出的模型，他们的模型和Mumford-Shah模型十分相似。我们以分割内外区域(即将图像分割成两部分)的问题介绍这一模型。如果我们已知分割区域内外的平均值 c_1, c_2 ，即函数 $c(x) = c_1, x$ 在区域内, 且 $c(x) = c_2, x$ 在区域外。通过优化

$$E(\Gamma) = \alpha \int_{\Gamma} ds + \frac{\lambda}{2} \int_{\Omega \setminus \Gamma} (u - c)^2 dx$$

应当也可以得到比较精确的分割。

回忆Mumford-Shah的优化模型(为方便设 $K = I$):

$$\min \alpha \int_{\Gamma} ds + \beta \int_{\Omega \setminus \Gamma} |\nabla u|^2 dx + \lambda \int_{\Omega} (u_0 - u)^2 dx$$

这二者在形式上就有些类似了。



Chan-Vese: 水平集分割

Chan和Vese进一步提出了通过水平集进行分割的模型：首先定义一个新的能量函数形式

$$F(c_1, c_2, C) = \mu \cdot \text{Length}(C) + \nu \cdot \text{Area}(\text{inside}(C)) \\ + \lambda_1 \int_{\text{inside}(C)} |u_0 - c_1|^2 dx + \lambda_2 \int_{\text{outside}(C)} |u_0 - c_1|^2 dx$$

事实上这与他们提出的原始形式只相差了一个曲线 C 内部的面积。



Chan-Vese: 水平集分割

Chan和Vese进一步提出了通过水平集进行分割的模型：首先定义一个新的能量函数形式

$$F(c_1, c_2, C) = \mu \cdot \text{Length}(C) + \nu \cdot \text{Area}(\text{inside}(C)) \\ + \lambda_1 \int_{\text{inside}(C)} |u_0 - c_1|^2 dx + \lambda_2 \int_{\text{outside}(C)} |u_0 - c_1|^2 dx$$

事实上这与他们提出的原始形式只相差了一个曲线 C 内部的面积。
引入水平集函数 $\phi: \Omega \rightarrow \mathbb{R}$ ，并且满足以下性质：

$$\begin{cases} C = \{x \in \Omega | \phi(x) = 0\} \\ \text{inside}(C) = \{x \in \Omega | \phi(x) > 0\} \\ \text{outside}(C) = \{x \in \Omega | \phi(x) < 0\} \end{cases}$$



Chan-Vese: 水平集分割

Chan和Vese进一步提出了通过水平集进行分割的模型：首先定义一个新的能量函数形式

$$F(c_1, c_2, C) = \mu \cdot \text{Length}(C) + \nu \cdot \text{Area}(\text{inside}(C)) \\ + \lambda_1 \int_{\text{inside}(C)} |u_0 - c_1|^2 dx + \lambda_2 \int_{\text{outside}(C)} |u_0 - c_1|^2 dx$$

事实上这与他们提出的原始形式只相差了一个曲线 C 内部的面积。
引入水平集函数 $\phi: \Omega \rightarrow \mathbb{R}$ ，并且满足以下性质：

$$\begin{cases} C = \{x \in \Omega | \phi(x) = 0\} \\ \text{inside}(C) = \{x \in \Omega | \phi(x) > 0\} \\ \text{outside}(C) = \{x \in \Omega | \phi(x) < 0\} \end{cases}$$

引入Heaviside函数 H 和其弱导数Dirac算子 δ ：

$$H(z) = \begin{cases} 1, & \text{if } z \geq 0 \\ 0, & \text{if } z < 0 \end{cases} \quad \delta(z) = \frac{d}{dz} H(z)$$



Chan-Vese: 水平集分割

立刻可以将能量泛函表示为:

$$\begin{aligned} F(c_1, c_2, C) = & \mu \int_{\Omega} \delta(\phi) |\nabla \phi| dx + \nu \int_{\Omega} H(\phi) dx \\ & + \lambda_1 \int_{\Omega} |u_0 - c_1|^2 H(\phi) dx \\ & + \lambda_2 \int_{\Omega} |u_0 - c_2|^2 (1 - H(\phi)) dx \end{aligned}$$

值得注意的是第一项 $Length(C) = \int_{\Omega} \delta(\phi) |\nabla \phi| dx$ 。



Chan-Vese: 水平集分割

立刻可以将能量泛函表示为:

$$\begin{aligned}
 F(c_1, c_2, C) = & \mu \int_{\Omega} \delta(\phi) |\nabla \phi| dx + \nu \int_{\Omega} H(\phi) dx \\
 & + \lambda_1 \int_{\Omega} |u_0 - c_1|^2 H(\phi) dx \\
 & + \lambda_2 \int_{\Omega} |u_0 - c_2|^2 (1 - H(\phi)) dx
 \end{aligned}$$

值得注意的是第一项 $Length(C) = \int_{\Omega} \delta(\phi) |\nabla \phi| dx$ 。

回忆co-area公式

$$\begin{aligned}
 \int_{\Omega} \delta(u) |\nabla u| dx &= \int_{-\infty}^{\infty} \delta(\lambda) Length(\gamma_{\lambda}) d\lambda \\
 &= Length(\gamma_0) = Length(C)
 \end{aligned}$$



Chan-Vese: 水平集分割

在水平集模型下, c_1, c_2 也可以求解(关于 c_1, c_2 极小化 F 即得):

$$c_1 = \frac{\int_{\Omega} u_0(x) H(\phi(x)) dx}{\int_{\Omega} H(\phi(x)) dx}, \quad c_2 = \frac{\int_{\Omega} u_0(x) (1 - H(\phi(x))) dx}{\int_{\Omega} (1 - H(\phi(x))) dx}$$



Chan-Vese: 水平集分割

在水平集模型下, c_1, c_2 也可以求解(关于 c_1, c_2 极小化 F 即得):

$$c_1 = \frac{\int_{\Omega} u_0(x) H(\phi(x)) dx}{\int_{\Omega} H(\phi(x)) dx}, \quad c_2 = \frac{\int_{\Omega} u_0(x) (1 - H(\phi(x))) dx}{\int_{\Omega} (1 - H(\phi(x))) dx}$$

为了方便数值计算, 我们将Heaviside函数光滑化:

$$H_{\epsilon}(z) = \frac{1}{2} \left[1 + \frac{2}{\pi} \arctan\left(\frac{z}{\epsilon}\right) \right], \quad \delta_{\epsilon}(z) = H'_{\epsilon}(z) = \frac{1}{\pi} \frac{\epsilon}{\epsilon^2 + z^2}$$

这时就可以计算梯度流、通过离散方法进行计算了



Chan-Vese: 水平集分割

在水平集模型下, c_1, c_2 也可以求解(关于 c_1, c_2 极小化 F 即得):

$$c_1 = \frac{\int_{\Omega} u_0(x) H(\phi(x)) dx}{\int_{\Omega} H(\phi(x)) dx}, \quad c_2 = \frac{\int_{\Omega} u_0(x) (1 - H(\phi(x))) dx}{\int_{\Omega} (1 - H(\phi(x))) dx}$$

为了方便数值计算, 我们将Heaviside函数光滑化:

$$H_{\epsilon}(z) = \frac{1}{2} \left[1 + \frac{2}{\pi} \arctan\left(\frac{z}{\epsilon}\right) \right], \quad \delta_{\epsilon}(z) = H'_{\epsilon}(z) = \frac{1}{\pi} \frac{\epsilon}{\epsilon^2 + z^2}$$

这时就可以计算梯度流、通过离散方法进行计算了

水平集演化过程中往往会出现梯度过大或过小的情况, 这不利于数值稳定性。使用re-initialization修正:

$$H(z) = \begin{cases} \psi_t = \text{sign}(\phi(t))(1 - |\nabla \psi|) \\ \psi(0, \cdot) = \phi(t, \cdot) \end{cases}$$

每次更新结束后再解出 ψ , 将 ψ 当做下一轮迭代的 ϕ 。



Local binary fitting

下面我们讨论一个具体的模型。

引自：Li, Chunming, et al. "Implicit Active Contours Driven by Local Binary Fitting Energy." Computer Vision and Pattern Recognition, 2007. CVPR '07. IEEE Conference on IEEE, 2007:1-7.



Chan-Vese方法利用水平集解决了迭代求解中的诸多问题，使得这一领域变得活跃起来。但是我们依旧能总结出他们方法中的诸多不足：



Chan-Vese方法利用水平集解决了迭代求解中的诸多问题，使得这一领域变得活跃起来。但是我们依旧能总结出他们方法中的诸多不足：

- 模拟内外部的 c_1, c_2 太粗糙，在内部有差异的模型中效果欠佳。医疗图像(如MRI等)往往呈现出这样的特点，所以Chan-Vese方法在医疗图像中效果不好。
- re-initialization比较繁琐，每次迭代后相当于又要做一次迭代。



Chan-Vese方法利用水平集解决了迭代求解中的诸多问题，使得这一领域变得活跃起来。但是我们依旧能总结出他们方法中的诸多不足：

- 模拟内外部的 c_1, c_2 太粗糙，在内部有差异的模型中效果欠佳。医疗图像(如MRI等)往往呈现出这样的特点，所以Chan-Vese方法在医疗图像中效果不好。
- re-initialization比较繁琐，每次迭代后相当于又要做一次迭代。

Chunming Li等人提出了基于Chan-Vese模型的改进模型：Local binary fitting。



方法

针对Chan-Vese模型的不足，李纯明提出了两点改进。



方法

针对Chan-Vese模型的不足，李纯明提出了两点改进。
其一是舍弃面积项(事实上面积项表意不明)，引入Signed distance regularization:

$$D(\phi) = \int_{\Omega} \frac{1}{2} (|\nabla \phi| - 1)^2 dx$$

这一项保证了 ϕ 具有接近于1的梯度，从而不再需要re-initialization作为修正。



方法

针对Chan-Vese模型的不足，李纯明提出了两点改进。
其一是舍弃面积项(事实上面积项表意不明)，引入Signed distance regularization:

$$D(\phi) = \int_{\Omega} \frac{1}{2} (|\nabla \phi| - 1)^2 dx$$

这一项保证了 ϕ 具有接近于1的梯度，从而不再需要re-initialization作为修正。

如果一个函数任意一点的值都可以表示为距离某个曲线/曲面的最短距离(在内部为正，在外部为负)，那么称这个函数为Signed distance function。Signed distance function都满足： $|\nabla \phi| = 1$ 。



方法

其二是引入了Local binary fitting: 尽管很多图像并不能在全局范围内设为二值, 但是他们在某点 $x \in \Omega$ 附近应当是可以近似二值化的。如果该点周围包含了内外边界, 那么局部二值拟合应该比全局二值拟合更加精确。

用数学语言来说, 就是 c_1, c_2 变成了函数 $f_1(x), f_2(x)$ 。并且在某一点周围我们只采集局部信息:



方法

其二是引入了Local binary fitting: 尽管很多图像并不能在全局范围内设为二值, 但是他们在某点 $x \in \Omega$ 附近应当是可以近似二值化的。如果该点周围包含了内外边界, 那么局部二值拟合应该比全局二值拟合更加精确。

用数学语言来说, 就是 c_1, c_2 变成了函数 $f_1(x), f_2(x)$ 。并且在某一点周围我们只采集局部信息:

$$E_x^{LBF}(C, f_1, f_2) = \lambda_1 \int_{inside(C)} K_\sigma(x - y) |I(y) - f_1(x)|^2 dy \\ + \lambda_2 \int_{outside(C)} K_\sigma(x - y) |I(y) - f_2(x)|^2 dy$$

其中 $K_\sigma(x) = \frac{1}{(2\pi)^{n/2}\sigma} e^{-|x|^2/2\sigma^2}$ 是Gauss核, 它的存在使得上式只采集局部信息, 较远的信息权重极小。



方法

使用水平集描述，就是：

$$\begin{aligned} E_x^{LBF}(\phi, f_1, f_2) = & \lambda_1 \int_{\Omega} K_{\sigma}(x - y) |I(y) - f_1(x)|^2 H(\phi(y)) dy \\ & + \lambda_2 \int_{\Omega} K_{\sigma}(x - y) |I(y) - f_2(x)|^2 (1 - H(\phi(y))) dy \end{aligned}$$



方法

使用水平集描述，就是：

$$E_x^{LBF}(\phi, f_1, f_2) = \lambda_1 \int_{\Omega} K_{\sigma}(x - y) |I(y) - f_1(x)|^2 H(\phi(y)) dy \\ + \lambda_2 \int_{\Omega} K_{\sigma}(x - y) |I(y) - f_2(x)|^2 (1 - H(\phi(y))) dy$$

全局能量函数表示为：

$$E^{LBF}(\phi, f_1, f_2) = \int_{\Omega} E_x^{LBF}(\phi, f_1, f_2) dx$$

再结合两个正则项我们得到：

$$F(\phi, f_1, f_2) = E^{LBF}(\phi, f_1, f_2) + \beta \int_{\Omega} \frac{1}{2} (|\nabla \phi| - 1)^2 dx + \nu \int_{\Omega} \delta(\phi(x)) |\nabla \phi(x)| dx$$

这就是总能量函数。



方法

是两点实现上的注意事项：



方法

是两点实现上的注意事项：

其一是对于Heaviside函数的光滑化与之前类似：

$$H_{\epsilon}(z) = \frac{1}{2} \left[1 + \frac{2}{\pi} \arctan\left(\frac{z}{\epsilon}\right) \right], \quad \delta_{\epsilon}(z) = H'_{\epsilon}(z) = \frac{1}{\pi} \frac{\epsilon}{\epsilon^2 + z^2}$$

对应的光滑化能量函数记为 $F_{\epsilon}(\phi, f_1, f_2)$



方法

是两点实现上的注意事项：

其一是对于Heaviside函数的光滑化与之前类似：

$$H_{\epsilon}(z) = \frac{1}{2} \left[1 + \frac{2}{\pi} \arctan\left(\frac{z}{\epsilon}\right) \right], \quad \delta_{\epsilon}(z) = H'_{\epsilon}(z) = \frac{1}{\pi} \frac{\epsilon}{\epsilon^2 + z^2}$$

对应的光滑化能量函数记为 $F_{\epsilon}(\phi, f_1, f_2)$

其二是迭代过程中对 $f_1(x), f_2(x)$ 的更新也是通过求极小化 F 得到的。

譬如将 F_{ϵ} 关于 f_1 求偏导得到：

$$\int_{\Omega} K_{\sigma}(x - y) H_{\epsilon}(\phi(y)) (I(y) - f_1(x)) dy = 0$$

即得

$$f_1(x) = \frac{K_{\sigma}(x) * [H_{\epsilon}(\phi(x)) I(x)]}{K_{\sigma}(x) * H_{\epsilon}(\phi(x))}$$

同理

$$f_2(x) = \frac{K_{\sigma}(x) * [(1 - H_{\epsilon}(\phi(x))) I(x)]}{K_{\sigma}(x) * (1 - H_{\epsilon}(\phi(x)))}$$

其中 $*$ 是卷积算子，离散化之后就是求和。



方法

下面求梯度流。根据变分求法可以得到：

$$\begin{aligned}\frac{\partial \phi}{\partial t} = & -\delta_{\epsilon}(\phi)(\lambda_1 e_1 - \lambda_2 e_2) + \nu \delta_{\epsilon}(\phi) \operatorname{div}\left(\frac{\nabla \phi}{|\nabla \phi|}\right) \\ & + \beta(\Delta \phi - \operatorname{div}\left(\frac{\nabla \phi}{|\nabla \phi|}\right))\end{aligned}$$

其中

$$e_1(x) = \int_{\Omega} K_{\sigma}(y-x) |I(x) - f_1(y)|^2 dy$$

$$e_2(x) = \int_{\Omega} K_{\sigma}(y-x) |I(x) - f_2(y)|^2 dy$$



方法

下面求梯度流。根据变分求法可以得到：

$$\begin{aligned} \frac{\partial \phi}{\partial t} = & -\delta_{\epsilon}(\phi)(\lambda_1 e_1 - \lambda_2 e_2) + \nu \delta_{\epsilon}(\phi) \operatorname{div}\left(\frac{\nabla \phi}{|\nabla \phi|}\right) \\ & + \beta(\Delta \phi - \operatorname{div}\left(\frac{\nabla \phi}{|\nabla \phi|}\right)) \end{aligned}$$

其中

$$e_1(x) = \int_{\Omega} K_{\sigma}(y-x) |I(x) - f_1(y)|^2 dy$$

$$e_2(x) = \int_{\Omega} K_{\sigma}(y-x) |I(x) - f_2(y)|^2 dy$$

推导



实现与结果

梯度用差分代替，卷积用求和代替



实现与结果

梯度用差分代替，卷积用求和代替
血管图像结果：



图: Vessel image result



实现与结果

大脑图像结果:




图: Brain image result



谢谢大家!